

PROBLÉMATIQUE ET OBJECTIF

Les entreprises croulent sous les messages clients (réseaux sociaux, forums, emails). Pourtant, elles peinent à capter rapidement le **sentiment** et à produire une **réponse contextualisée**.

L'objectif est de construire un pipeline modulaire capable de faire les deux, en s'appuyant sur des modèles de langage fine-tunés.

SUITE LOGIQUE

Lors du premier hackathon, on a pris de la hauteur pour capter les grandes tendances autour du climat. Cette fois, on zoome : on entre dans le détail des émotions, des intentions, et des réponses possibles...

...pour passer de l'analyse à l'action!

DÉFIS CLÉS

- 1. Comprendre des textes courts et ambigus
- 2. Gérer l'ironie, les émojis, les fautes
- 3. Générer des réponses pertinentes, personnalisées, et instantanées
- 4. Combiner classification et génération dans un même pipeline fluide



- 1. Prétraitement : nettoie et normalise le texte
- 2. Sentiment : détecte l'émotion du message
- 3. **Thème** : comprend de quoi parle le message
- 4. Intention : identifie la nature de la demande
- 5. **Génération** : propose une réponse pertinente
- 6. Filtrage : valide la cohérence de la réponse
- 7. Visualisation : rend les prédictions compréhensibles
- 8. Interface : permet de tester tout le système



Module 1 – Prétraitement des Données

- Objectif : Nettoyer et normaliser le texte en entrée
- Actions clés :
 - o Suppression des URL, mentions, hashtags
 - o Gestion des emojis, contractions et fautes
 - Tokenisation et lemmatisation
- Pourquoi ?
 Pour fournir des entrées propres et standardisées aux modèles de NLP.

Prétraitement Nettoie et normalise le texte brut pour le rendre exploitable par les modèles. NLTK, spaCy, re, emoji, unidecode

Module 2 – Analyse de Sentiment

- Modèle : RoBERTa (ou DistilBERT) fine-tuné
- Sortie : Sentiment classé en positif, neutre, ou négatif
- Spécificité :
 - Fine-tuning réalisé sur un dataset issu de Reddit et Twitter
 - o Prise en compte du contexte sémantique, même implicite

1. 2. Analyse de Sentiment Détecte l'émotion dominante du message (positif, neutre, négatif). \(^\circ\) Outils : RoBERTa, Hugging Face Transformers, sklearn, datasets, pipeline

Module 3 – Détection de Thème ou Sujet

- Approche: Topic Modeling (LDA ou KMeans sur embeddings)
- But : Identifier si le texte parle de service, produit, logistique, etc.
- Intérêt : Affiner la réponse en fonction du contexte métier

1. 3. Détection de Thème ou Sujet Comprend le contenu principal du message (ex. livraison, produit, service). \(^\circ\) Outils : TF-IDF, LDA (gensim), KMeans, UMAP ou TSNE

Module 4 – Classification de l'Intention

- **Tâche**: Identifier l'intention du message:
 - ∘ 🖊 Plainte, 7 Question, 🙏 Remerciement, 🗸 Avis positif, 🔁 Demande d'a
- Techno : Modèle supervisé entraîné sur des catégories explicites
- Usage : C'est la brique clé pour conditionner le ton de la réponse
- 1. 4. Classification de l'Intention Identifie si le message est une plainte, une question, un remerciement, etc. \(^\infty\) Outils: LogisticRegression, SVC, ou transformers fine-tunés, sklearn

Module 5 – Générateur de Réponse Contextuelle

- Modèle: Falcon-7B ou LLaMA, avec prompt dynamique
- Entrée : Sentiment + Intention + Thème
- Sortie : Réponse personnalisée, empathique, contextuelle
- Contrôle : On évite les réponses génériques avec des règles + prompt templates

1. 5. Génération de Réponse Contextuelle Propose une réponse cohérente et adaptée au sentiment et à l'intention. \(^\infty\) Outils : Falcon-7B, transformers, Prompt Engineering, LangChain, PEFT

Module 6 – Score de Pertinence et Filtrage

- Objectif : Valider que la réponse générée est bien alignée avec le message d'ori
- Méthode :
 - o Score de similarité sémantique (cosine similarity avec embeddings)
 - o Rejet des réponses incohérentes ou trop longues
- Valeur ajoutée : Évite les hallucinations ou les incohérences

1. 6. Score de Pertinence et Filtrage Valide que la réponse est alignée avec le message d'origine. \(^\circ\) Outils : Sentence Transformers, cosine_similarity, faiss, règles de filtrage

Module 7 – Visualisation des Résultats

- Techno: Matplotlib, seaborn, WordCloud
- Affichage :
 - Sentiment global
 - Répartition des intentions
 - Nuage de mots
- Utilité : Aide à interpréter rapidement un ensemble de messages

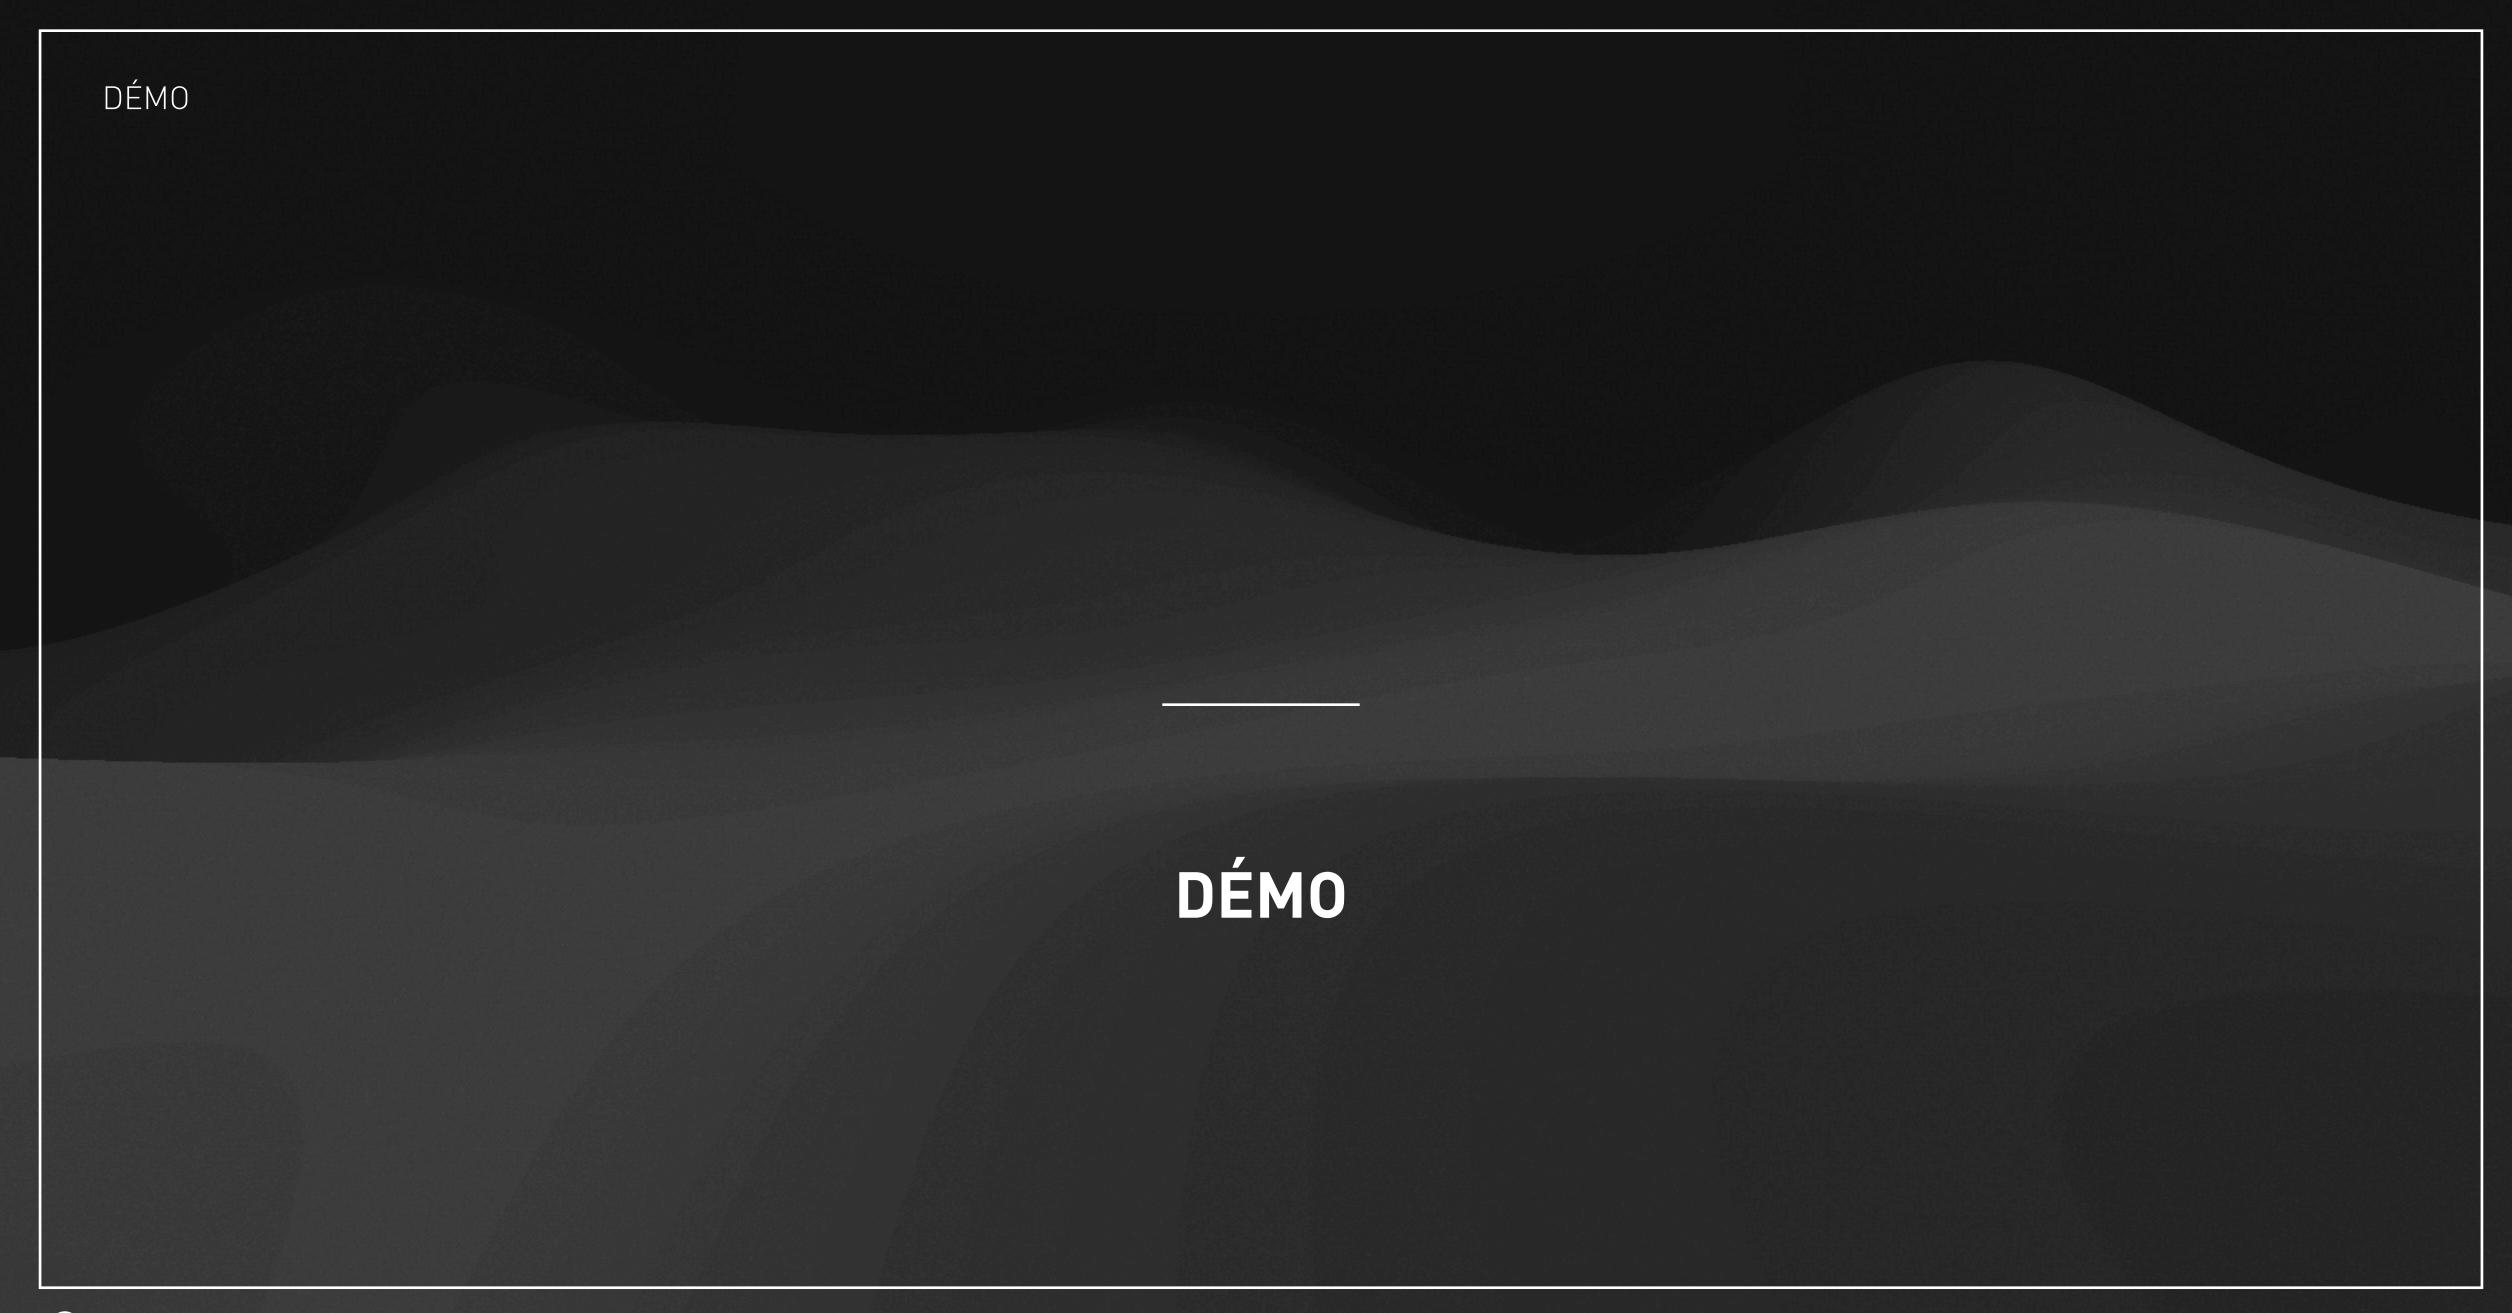
1. 7. Visualisation des Résultats Rend les prédictions et le traitement interprétables en un coup d'œil. \(^\) Outils : matplotlib, seaborn, WordCloud, Plotly

Module 8 – Interface & Démo Utilisateur

- Interface simplifiée en local ou via notebook
- Fonctions :
 - Entrée texte manuelle ou batch
 - o Affichage des prédictions + réponse générée
 - Visualisation en live
- Vision : Permettre à un non-technicien de tester le pipeline complet

1. 8. Interface & Démo Utilisateur Permet de tester le système de bout en bout via une interface simple. \(^\circ\) Outils: Jupyter Notebook, Gradio, ou Streamlit (optionnel), IPython.display

```
FLOWCHART
      Texte brut
      Prétraitement (Module 1)
      Sentiment (Module 2) + Contexte (Module 3)
      Génération de réponse (Module 4)
      Visualisation (Module 5)
```



Ce projet offre un pipeline IA modulaire pour analyser les sentiments climatiques, combinant prétraitement automatisé, fine-tuning léger, visualisation, génération de réponses et interface interactive.

Facilement déployable via Streamlit, il répond aux défis de données hétérogènes et d'interprétabilité grâce à des choix techniques efficaces comme LoRA, PEFT et embeddings.

Ce projet permet aux professionnels de la communication, de la veille ou de la RSE de mieux comprendre les perceptions liées au climat en exploitant automatiquement les émotions, intentions et thématiques exprimées dans les discours en ligne.



ET SI DEMAIN, CES OUTILS DEVENAIENT DES ASSISTANTS DE DÉCISION POUR LA TRANSITION ÉCOLOGIQUE, JUSQU'OÙ POURRIONS-NOUS ALLER COLLECTIVEMENT ?

Merci! À vos questions